

Cookie Cats A/B 測試評估

該不該把卡關門檻從第 30 關移到第 40 關？

jenho.cheng · PM Portfolio · 2026

Python · scipy · statsmodels · Bayesian · Streamlit

業務情境

Tactile Games 旗下 *Cookie Cats* — 連連看 + 解謎手遊, > 1 億下載量

實驗設計: 把首次卡關門檻從第 30 關移到第 40 關

- **gate_30** (對照組): 44,700 玩家
- **gate_40** (實驗組): 45,489 玩家
- 觀察期: 安裝後 14 天

業務假設: 玩家少被卡 → 留存應該提升 → ship gate_40

問題: 這個假設成立嗎?

第一件事 — 不是看指標,是檢查實驗本身

組別	玩家數	比例
gate_30	44,700	49.56%
gate_40	45,489	50.44%

理論 50/50,實際 chi-square test → $p = 0.0086$

= SRM (Sample Ratio Mismatch) 異常

業界標準 (Microsoft / Google / Airbnb):SRM $p < 0.01$ 的實驗結果不該採信。
通常代表 randomization 有 bug — 某裝置/地區/版本只進其中一組,結果失真。

PM 行動:不 share 結果給 leadership,先請工程 debug randomization

若忽略 SRM 強行分析:三種方法 vs 同一結論

方法 1 — Frequentist 2-proportion z-test

指標	對照	實驗	差異	p-value	95% CI
Day 1 留存	44.82%	44.23%	-0.59pp	0.074	[-1.24, +0.06]
Day 7 留存	19.02%	18.20%	-0.82pp	0.0016	[-1.33, -0.31]

D7 顯著差異($p < 0.01$), 95% CI 完全在 0 以下。

D1 邊緣不顯著, 但 **post-hoc power 只有 0.43** — under-powered, 不能因此 conclude 「沒差異」。

方法 2 — Bootstrap 重抽 10K 次

指標	平均差異	95% Bootstrap CI	P(gate_40 更差)
Day 1 留存	-0.59pp	[-1.23, +0.05]pp	96.3%
Day 7 留存	-0.82pp	[-1.33, -0.31]pp	100%

Day 7 全部 10,000 次重抽都顯示 gate_40 更差 — 結論非常 robust

Bootstrap 不假設分布形狀,不需要常態假設,直接用資料估計不確定性。
比 Frequentist 更直觀:不講 p-value,直接給「比較差的機率」。

方法 3 — Bayesian Beta-Binomial

Jeffreys prior $\text{Beta}(0.5, 0.5)$, 200,000 次後驗抽樣

指標	P(gate_40 better)	95% Credible Interval
Day 1 留存	3.7%	[-1.24, +0.06]pp
Day 7 留存	0.1%	[-1.33, -0.31]pp

Bayesian 給的是「**假設為真的直接機率**」, 不像 Frequentist 的 p-value 那樣繞口。
 $P(\text{gate_40 better}) = 0.001 \rightarrow$ 業務語言: 「**gate_40 比較好的機率約 1/1000, 等於確定不該 ship**」。

三方法都指向同一結論

方法	結論
Frequentist	D7 顯著更差 ($p=0.0016$)
Bootstrap	D7 100% 重抽顯示更差
Bayesian	D7 $P(\text{better}) = 0.001$

為什麼用三種方法？

- 單一方法可能受假設侷限(Frequentist 假設常態、Bayesian 受 prior 影響)
- 三角驗證 = 結論 robust
- 對不同受眾講不同語言:技術人聽 p-value,業務聽機率

🎯 PM 決策:不要 ship gate_40

三層理由

1. 🚨 SRM 異常 ($p=0.0086$) — 業界標準會擋下這個實驗,先修 randomization
2. 📉 若強行解讀:Day 7 留存 $-0.82pp$,三種方法一致
3. 🎯 業務上不小:Cookie Cats 規模(每日新裝 10 萬) $\rightarrow -0.82pp = 30,000$ 玩家/月流失

為什麼直覺錯了?三個假設

假設	為什麼可能成立	怎麼驗證
承諾機制	卡關產生「未完成感」(Zeigarnik effect)促玩家回來	比較卡關玩家 vs 未卡關的長期留存
IAP 觸發點	第 30 關是「願付費」最佳時機,40 關錯失轉換	看 ARPU / 付費轉換率
社群催化	卡關玩家會去查攻略 / 找朋友 → 提升黏著	看社群行為 / 攻略搜尋量

啟示:門檻不是「障礙」,是某種**正向機制**。下次設計實驗前要先想「這個 feature 在做什麼」,而不只是「移除它應該更好」。

下一個實驗該怎麼設計

1. 測 **gate_35** — 找甜蜜點(線性外推不一定成立,要驗)
2. 測「**移除 gate 但加每日任務**」 — 用每日任務取代強制卡關,維持承諾感
3. 加 **segment 分析** — 新手 vs 老玩家可能反應不同
4. 加**營收指標** — 留存差但 ARPU 高也可能 ship,目前資料不足
5. **重跑時樣本量加大 4 倍** — D1 power 0.43,需更大樣本才能定論

從這個案子學到什麼

- ✓ A/B 測試的存在就是為了破除直覺 — 結果跟直覺一樣的實驗就是浪費錢
- ✓ 第一件事是檢查實驗本身(SRM、樣本量、power),再看指標
- ✓ 三種方法交叉驗證 = 結論 robust,單一方法可能有死穴
- ✓ 效應大小 vs 統計顯著要分開看 — $p < 0.05$ 不代表業務上重要

我的差異化 vs 多數 PM portfolio

多數 PM 履歷的 A/B 案例	我的做法
看 p-value < 0.05 就 conclude	先檢查 SRM, 業界標準作法
只用 t-test 或只用 Bayesian	三方法交叉驗證
不算 power	post-hoc power 0.43 → 知道哪個結論不可信
結論 = ship/no-ship	結論 = ship/no-ship + 為什麼 + 下個實驗
不質疑業務假設	直覺被推翻時提出三個可驗證假設

